

Fraudia

Detector de Posibles Fraudes en Siniestros

Motor de reglas · XGBoost · SHAP · Agente Groq LLaMA



El problema: el fraude en seguros es costoso e invisible

El fraude en siniestros de seguros genera pérdidas millonarias que terminan pagando todos los asegurados a través de primas más altas.

El reto es identificar casos sospechosos **antes del pago**, sin frenar el flujo de casos legítimos ni acusar sin pruebas.

5–10%

de siniestros
contienen fraude

14.4%

del dataset
son alertas simuladas

1,000

siniestros
analizados

Arquitectura del sistema



Score híbrido = Motor de reglas $\times$ 0.6 + XGBoost $\times$ 0.4 → ● Rojo (76-100) · ● Amarillo (41-75) · ● Verde (0-40)

⚠ El sistema genera alertas de revisión. Toda alerta requiere análisis humano antes de cualquier decisión.

Dos capas complementarias de inteligencia

⚙️ Motor de Reglas — 60%

RF-01 Proveedor + borde de vigencia → ●

RF-02 Inconsistencia documental → ●

RF-03 Lista restrictiva → ●

RF-05 Siniestro en primeras 48 h → ●

RF-06 Robo sin parte policial → ●

Señales acumulativas (7 indicadores)

🤖 XGBoost + SHAP — 40%

16 features derivadas del dataset

Umbral ajustado a 0.3 (negocio)

scale_pos_weight = 5.67 (desbalance)

SHAP: explica cada predicción

Top driver: ratio_monto_suma_asegurada

Entrenado en Google Colab

Las señales discriminan — evidencia estadística

% de posible fraude CON señal vs. SIN señal (Notebook 01 — 1000 siniestros)

Señal	Casos	Con señal	Sin señal	Ratio
Monto > 95% suma asegurada	35	54.3%	13.0%	4.2×
Borde de vigencia (≤ 10 días)	29	48.3%	13.4%	3.6×
Reporte tardío (> 7 días)	61	47.5%	12.2%	3.9×
Documento inconsistente	41	46.3%	13.0%	3.6×
Proveedor lista restrictiva	97	26.8%	13.1%	2.0×
Documentos incompletos	133	24.1%	12.9%	1.9×
Alta frecuencia asegurado	405	20.2%	10.4%	1.9×

Resultados del modelo — y por qué son aceptables

0.5566

AUC-ROC

datos sintéticos

55%

Recall (fraude)

umbral 0.3

18%

Precision

trade-off consciente

35

Tests pasando

22 reglas + 13 features

¿Por qué el AUC bajo es aceptable?

1. El modelo ML aporta solo el 40% del score — el 60% viene del motor de reglas (determinista y validable).
2. Datos 100% sintéticos no capturan patrones reales. Con datos reales, AUC-ROC esperado > 0.75 .
3. El umbral 0.3 prioriza recall: es peor no detectar un fraude que revisar un caso de más.
4. Cada alerta incluye explicación SHAP — el analista siempre sabe por qué se marcó el caso.

Explicabilidad y compromiso ético



SHAP — Por qué se marcó cada caso

- ▶ Calcula la contribución de cada feature a la predicción individual
- ▶ Top driver: ratio_monto_suma_asegurada (+2.35)
- ▶ Texto legible para el analista generado automáticamente
- ▶ Gráficas de importancia global y por caso en notebook 03



Principios Éticos

- El sistema genera alertas de revisión, no acusaciones
- Toda decisión requiere análisis humano previo
- Lenguaje: 'posible fraude' o 'requiere revisión'
- Datos 100% sintéticos, sin PII real en el repo

Demo en vivo — Dashboard Streamlit



Bandeja de casos ordenada por score
con filtros por semáforo y ramo



Detalle individual con alertas, SHAP
y explicación generada por IA



Agente conversacional LLaMA 3.3-70B
responde las 12 preguntas del reto



Semáforo verde / amarillo / rojo
con recomendación de acción

Preguntas sugeridas para el jurado

*"¿Qué proveedores concentran el 80%
de las alertas rojas?"*

"¿Por qué el SIN-000005 es rojo?"

*"¿Qué ramos tienen mayor porcentaje
de casos sospechosos?"*

*"Genera un resumen ejecutivo
de los casos críticos."*

*"¿Qué casos debería revisar primero
el analista?"*



Fraudia detecta. El analista decide.

Motor de reglas · XGBoost · SHAP · Agente Groq LLaMA

github.com/Shermy143/fraudia-claims | fraudia-claims.streamlit.app